

Questions complémentaires du 15 septembre : profil d'erreur, fenêtre d'accumulation, matrice de corrélation

Cadre

Ce document répond au mail du 15 septembre 2026, reproduit dans `01_consignes/Questions_bis_15sept.md`. Il ne modifie rien du rapport ni des rédactions déjà rendues : il s'ajoute à elles.

Les énoncés complets des cinq questions n'ont pas été lus. Le fichier reçu est le corps du mail rendu en HTML, et c'est la seule pièce jointe parvenue au groupe. Les réponses suivent donc le texte du mail, question par question, dans l'ordre de priorité qu'il donne : C.3.bis, C.2.bis, D.3.bis, D.1.bis, C.1.bis.

Tout est recalculé hors ligne par `resultats_R2/scripts/analyse_bis.py` depuis les Parquet de la campagne de 2 000 exécutions (20 amplitudes $\times$ 100 graines, horizon $H = 2\,000$ pas, forêt de $M = 10$ arbres, $\delta_P = 0.01$). Aucune simulation n'a été relancée, à une exception près, annoncée en section 4 : la variance entre arbres n'était calculable depuis aucune table, et un pilote instrumenté a été lancé pour elle. Chaque chiffre cité se lit dans une table `QCD_bis_*.parquet` nommée en note à sa première occurrence.

Notation. Les nombres suivent la notation décimale du reste du dépôt, point décimal, pour que le contrôle de traçabilité `verif_chiffres_tex.py` s'applique à ce document sans être modifié. Le reste de la notation est celle du rapport, sans changement : τ_{ARF} date du premier remplacement d'arbre, $\tau_{\text{swap}}(q)$ date du renouvellement d'une fraction q de la forêt, τ_{det} date de l'alarme du détecteur, $A(H)$ aire d'erreur excédentaire sur l'horizon complet, $A(0, w)$ la même sur la fenêtre courte, $S_{\text{max}}(H)$ statistique du détecteur, $\hat{p}_0$ socle d'erreur pré-rupture estimé sur 3 000 pas, Δe amplitude du changement.

Ce que le mail change au cadre. L'encadrant tranche que A est la métrique de référence de l'adaptation du classifieur, S_{max} restant celle du détecteur. Les questions ci-dessous adoptent cette lecture. Elle est compatible avec la réponse de la question D du rapport, qui sépare déjà les deux : τ_{ARF} ne dit rien de $A(H)$ et porte une association faible avec $S_{\text{max}}(H)$.

1 C.3.bis : le profil d'erreur après la rupture

Réponse. L'erreur décroît d'un niveau de départ mesuré vers un palier e_∞ qui n'est pas $\hat{p}_0$: il passe en dessous aux vingt amplitudes, et l'écart dépasse deux erreurs types aux trois plus fortes. Le temps caractéristique de cette décroissance ne suit ni τ_{ARF} ni la loi $18.5 \Delta e^{-0.98}$ de l'article. Il dépasse τ_{ARF} médian sur 17 des 18 amplitudes lisibles, d'un facteur 0.8745 à 1.5625, mais l'intervalle de confiance de $t_{1/2}$ ne l'en sépare que sur 8 d'entre elles : l'énoncé prudent est que les deux horloges sont du même ordre, avec un avantage à $t_{1/2}$. Contre la loi de l'article, le rapport passe de 1.822 à $\Delta e = 0.141$ à 0.818 à $\Delta e = 0.498$: elle est trop courte en bas de grille et trop longue en haut. Enfin le profil n'est pas exponentiel là où sa forme est mesurable : le rapport $t_{90}/t_{1/2}$ y vaut 1.4839 à 1.8286, contre $\ln 10 / \ln 2 = 3.3219$.

1.1 Définitions, posées avant les mesures

Le profil moyen $\bar{e}_t$ est la moyenne sur les 100 graines de l'amplitude, sans aucun lissage temporel : un filtre de longueur L décale tout marqueur de $L/2$, et la table ne porte donc que la moyenne inter-graines.

Le palier e_∞ est la moyenne de $\bar{e}_t$ sur la fenêtre [1500;2000), *déclarée avant mesure* et disjointe du transitoire. Elle reproduit exactement, à $3.5 \cdot 10^{-18}$ près, la colonne `erreur_fin_horizon` de

QCD_fin_horizon_full à la fenêtre 500, ce qui sert de contrôle de non-régression.¹ Sa fiabilité est testée par amplitude : l'écart entre les moyennes sur [1500;1750) et [1750;2000) est comparé à deux fois son erreur type inter-graines. Deux amplitudes sur vingt échouent ce test, $\Delta e = 0.390998$ et $\Delta e = 0.465040$; leurs lignes restent dans la table, marquées, et la section 6 dit ce que cela coûte.

Le niveau de départ e_{start} est *mesuré*, moyenne de $\bar{e}_t$ sur [0; 5), soit 500 observations. La valeur théorique $\hat{p}_0 + \Delta e$ ne sert que de colonne de contrôle : le rapport a déjà établi qu'elle est réfutée sur les vingt amplitudes, et l'employer au dénominateur fabriquerait un temps de demi-vie là où il n'y en a pas.

Le temps de fraction t_q est le premier instant où la moyenne de $\bar{e}$ sur une fenêtre de 20 pas passe sous $e_\infty + (1 - q)(e_{\text{start}} - e_\infty)$. Il porte un indicateur de lisibilité par fraction : t_q ne se cite que si la marge $(1 - q)(e_{\text{start}} - e_\infty)$ dépasse deux erreurs types au niveau franchi. Pour $q = 0.50$, deux amplitudes échouent, $\Delta e = 0.028$ et $\Delta e = 0.085$; pour $q = 0.90$, douze.

1.2 Pourquoi la règle de persistance a dû changer

La règle appliquée dans le projet jusqu'au 15 septembre exige qu'un seuil soit franchi et *tenu 20 pas consécutifs*. Sur le cas synthétique où la réponse est connue, un transitoire exponentiel de constante $\theta = 100$ dont la demi-vie vaut $\theta \ln 2 = 69.3147$, elle donne $t_{1/2} = 112$, soit 62% de trop. La cause est que le bruit binomial à 100 graines vaut environ ± 0.038 au niveau franchi : un seul pas au-dessus du seuil casse la fenêtre, et l'instant retenu attend que la courbe soit descendue bien plus bas.

La règle appliquée ici est le franchissement *en moyenne* sur la même fenêtre de 20 pas. C'est toujours une persistance, un pas isolé ne déclenche rien, mais le bruit y est divisé par $\sqrt{20}$. Sur le même tirage, elle donne $t_{1/2} = 62$ pour la même vérité de 69.3147.² Les deux valeurs sont dans la table, l'ancienne règle comme la nouvelle : c'est ce contrôle qui a fait changer d'estimateur, et le biais résiduel, de l'ordre de la moitié de la fenêtre de persistance, vaut pour toutes les valeurs de t_q publiées ici.

1.3 Ce que donne la mesure

Δe	e_{start}	e_∞	t_{25}	$t_{1/2}$	t_{90}	τ_{ARF} médian
0.028	0.0240	0.022040	99	296	303	118
0.141	0.1260	0.021420	110	230	608	263
0.287	0.2940	0.019080	51	100	222	64
0.498	0.5060	0.002440	23	30	45	28

TABLE 1 – Quatre amplitudes représentatives. La ligne $\Delta e = 0.028$ est donnée pour mémoire : ses trois temps de fraction échouent au test de lisibilité. La table complète, à vingt amplitudes, avec les intervalles de confiance bootstrap et les indicateurs, est dans QCD_bis_demi_vie.parquet.

À $\Delta e = 0.498$, $t_{1/2} = 30$ pas, intervalle [28; 32], contre un τ_{ARF} médian de 28 pas et une prédiction de l'article de 36.659. À $\Delta e = 0.141$, $t_{1/2} = 230$ pas, intervalle [166; 304], contre un τ_{ARF} médian de 263 et une prédiction de 126.209. C'est la seule amplitude lisible où $t_{1/2}$ passe *sous* τ_{ARF} , et elle suffit à interdire la formule « le profil est partout plus lent que le premier remplacement ».

Un intervalle bootstrap sur un instant de franchissement n'a de sens que si l'instant est défini dans la plupart des rééchantillons. Le taux de rééchantillons sans franchissement est publié avec chaque intervalle : il vaut 0.0000 aux dix-neuf amplitudes à partir de $\Delta e = 0.085$, pour les trois fractions, et 0.3980 à $\Delta e = 0.028$.

Le palier mérite d'être lu pour lui-même. e_∞ est inférieur à $\hat{p}_0$ aux vingt amplitudes, mais l'écart n'excède deux erreurs types qu'aux trois plus fortes ; il y culmine à $z = 4.1896$ pour $\Delta e = 0.498$, où $e_\infty = 0.002440$ contre un socle $\hat{p}_0 = 0.023110$. L'erreur finit alors à un dixième de son niveau d'avant la rupture. C'est l'acquis déjà consigné selon lequel la tâche devient plus facile après le changement, et il interdit de lire $A(H)$ comme une quantité d'erreur subie.

1. QCD_bis_profil_erreur.parquet, QCD_bis_demi_vie.parquet.

2. QCD_bis_self_check.parquet, contrôle C2bis_a2_bernoulli, lignes t_half_regle_pas_a_pas et t_half.

1.4 La forme du profil

Le test de forme n'est pas le recalage des courbes en $t/t_{1/2}$: toute courbe y passe par 0.5 en $x = 1$ par construction, et valider une métrique par une autre qui lui est liée est le piège recensé au journal. La figure du recalage est donnée pour l'illustration, et légendée comme telle.

Le test est le rapport $t_{90}/t_{1/2}$. Pour une exponentielle pure il vaut exactement $\ln 10 / \ln 2 = 3.3219$. Sur les huit amplitudes où t_{90} est lisible, il vaut de 1.4839 à 1.8286, et la borne haute la plus élevée des huit intervalles de confiance est 1.9714. La valeur 3.3219 est donc exclue partout où la forme est mesurable : le profil décroît plus vite qu'une exponentielle en fin de transitoire.

Ce verdict porte une faiblesse qu'il faut écrire avec lui. Le rapport $t_{90}/t_{1/2}$ décroît avec l'amplitude, corrélation de Spearman -0.5107 pour $p = 0.0214$, et le critère de lisibilité ne se lève lui aussi qu'en haut de grille, parce que la marge $0.1(e_{\text{start}} - e_{\infty})$ y croît tandis que $2se$ reste plat. Le tri et l'effet vont donc dans le même sens, et les huit amplitudes retenues sont précisément celles où le rapport est le plus bas : sa moyenne y vaut 1.6066 contre 2.3385 aux douze autres. Aux deux amplitudes immédiatement inférieures au seuil, $\Delta e = 0.326793$ et $\Delta e = 0.361418$, l'intervalle de confiance du rapport contient 3.3219. Le compte de huit est lui-même fragile : le rapport de la marge à $2se$ vaut 1.0056 à $\Delta e = 0.465040$ et 0.9774 à $\Delta e = 0.452271$, de sorte que deux décimales de bruit le feraient basculer entre sept et neuf.

Ce qui est établi est donc étroit : *aux amplitudes les plus fortes*, le profil n'est pas exponentiel. Aux douze autres, la forme n'est pas distinguable d'une exponentielle sous ce protocole, et rien ne permet d'étendre le verdict.

1.5 Le témoin sans drift

Sur les 2000 exécutions sans rupture, $e_{\text{start}} = 0.020700$ et $e_{\infty} = 0.022843$: la baisse mesurée est *négative*, -0.002143 . Aucun t_q n'est défini et aucun indicateur de lisibilité ne se lève. L'estimateur ne fabrique pas de dynamique là où il n'y en a pas. Ce témoin tourne sur 2000 graines quand la mesure en utilise 100 par strate : son bruit est $\sqrt{20}$ fois plus faible, et il ne teste donc pas le régime exact dans lequel t_q est calculé.




FIGURE 1 – Profil d'erreur post-rupture. À gauche le transitoire, avec les marqueurs τ_{ARF} médian, $t_{1/2}$ et t_{90} . À droite l'horizon complet en moyennes par blocs disjoints de 100 pas, qui montre le palier passant sous $\hat{p}_0$ aux fortes amplitudes.




FIGURE 2 – Le pont avec l'article. $t_{1/2}$ dépasse τ_{ARF} médian sur 17 des 18 amplitudes lisibles ; l'exception, $\Delta e = 0.141$, est visible sur la figure, où la courbe de τ_{ARF} passe au-dessus de celle de $t_{1/2}$. La loi $18.5\Delta e^{-0.98}$ coupe les deux.




FIGURE 3 – Illustration seulement. Le recalage par $t_{1/2}$ force toutes les courbes à passer par 0.5 en $x = 1$; il ne teste pas la forme.

2 C.2.bis : quelle fenêtre w pour $A(0, w)$

Réponse. Le rapport signal sur bruit de $A(0, w)$ a bien un maximum intérieur, et l'intuition du mail est confirmée : prolonger l'accumulation noie l'adaptation. Mais la réponse n'est pas une fenêtre, c'est un intervalle. La fenêtre de certificat imposée par l'énoncé, $w = 3 \cdot 18.5 / \Delta e$, est trop longue sur dix-neuf amplitudes sur vingt : elle vaut 1.77 à 2.49 fois w_{opt} sur le haut de la grille, $\Delta e \geq 0.4$, et 3.978 fois à $\Delta e = 0.028$. Elle est en revanche plus *courte* que w_{opt} à $\Delta e = 0.141$, où le rapport vaut 0.885, et ce contre-exemple interdit d'en faire une règle. Au-delà d'un certain w , en haut de grille, $\mu(w)$ change de signe et le rapport devient négatif : accumuler plus longtemps ne dégrade pas seulement la mesure, elle en inverse le sens.

2.1 Le cadre

Avec $A(0, w) = \sum_{t=0}^{w-1} (e_t - \hat{p}_0)$, l'espérance $\mu(w) = \sum_{t < w} (\bar{e}_t - \hat{p}_0)$ croît pendant le transitoire puis plafonne au milieu de la grille, où $e_\infty \approx \hat{p}_0$, et *décroît* en haut de grille, où $e_\infty < \hat{p}_0$. Le contrôle de non-régression est immédiat : $A(0, 2000)$ reproduit la colonne `A_H` de `QCD_indicateurs_full` à $6.0 \cdot 10^{-12}$ près.³

La variance est mesurée sur les graines, et rien d'autre. La formule binomiale $\sum_t \bar{e}_t(1 - \bar{e}_t)$ est fausse sur ces données : le rapport de l'écart-type empirique à cet écart-type théorique vaut 0.6001 à $w = 50$ et 1.5866 à $w = 2000$ pour $\Delta e = 0.498$. Une forêt qui apprend produit une erreur autocorrélée et un effet de graine que la formule ignore dans les deux sens. Elle ne sert ici qu'à l'illustration.

Le rapport $\text{SNR}(w) = \mu(w)/\sigma(w)$ a un maximum intérieur. C'est la formalisation de l'accumulation prolongée qui noie le transitoire. Dans le cas fermé d'un transitoire exponentiel $\bar{e}_t - \hat{p}_0 = \Delta e e^{-t/\theta}$ avec un bruit d'écart-type *constant*, on a $\text{SNR}(w) \propto (1 - e^{-w/\theta})/\sqrt{w}$, maximal en $w_{\text{opt}} = 1.2564\theta$, racine de $2xe^{-x} = 1 - e^{-x}$.

2.2 Pourquoi ce cas fermé ne suffit pas

Le contrôle sur cas connu sépare deux situations que le cadre confondait. Avec un bruit additif d'écart-type constant, la formule s'applique et l'intervalle W_{95} estimé sur 100 graines, $[110; 230]$, contient bien la vérité 125.64. Avec des tirages de Bernoulli, dont la variance $p_t(1 - p_t)$ décroît avec le transitoire, la vérité calculée sur 20000 graines vaut 285, soit 2.85θ et non 1.2564θ .⁴ La formule fermée ne transporte donc pas sur des données binaires, et la fenêtre qu'elle suggère est *plus courte* que l'optimum, d'un facteur voisin de deux sur ce cas.

À 100 graines, l'argmax seul n'a de toute façon pas de contenu : sur le témoin à bruit corrélé, la largeur de W_{95} vaut 0.8462 fois w_{opt} . La lecture porte donc sur $W_{95} = \{w : \text{SNR}(w) \geq 0.95 \max\}$, dont la couverture est validée sur 100 réplifications de 100 graines : l'intervalle bootstrap contient la vérité dans 0.9700 des cas et intersecte le W_{95} vrai dans 1.0000 des cas.

Ce témoin à bruit corrélé ne reproduit qu'en partie le régime des données. Son rapport d'écart-type empirique à écart-type binomial vaut 0.9665 à $w = 50$ et 2.0582 à $w = 2000$, quand les données donnent 0.6001 et 1.5866. Le sens est le bon, sous 1 en fenêtre courte et au-dessus en fenêtre longue, mais l'amplitude ne l'est pas : la couverture validée sur ce témoin ne transporte donc pas telle quelle.

Le témoin sans signal lève bien son drapeau, mais pas par le critère prévu. Les deux critères du plan, w_{opt} sur une borne de la grille et W_{95} couvrant la moitié de celle-ci, *échouent* tous les deux à $\Delta e = 0$: l'argmax tombe au milieu de la grille sur un pic de bruit et son W_{95} est étroit. Le critère qui se lève a été ajouté après cet échec : le maximum de SNR reste sous $3/\sqrt{n} = 0.3000$. Les trois lignes sont dans la table des contrôles, les deux échecs compris.

2.3 Ce que donne la mesure

Le plateau est réel en bas de grille et étroit en haut : à $\Delta e = 0.028$, SNR_{max} ne vaut que 0.949, et l'intervalle bootstrap de l'argmax s'étend de 285 à 970. Citer un w_{opt} ponctuel y serait une sur-lecture. À $\Delta e = 0.498$, $W_{95} = [43; 47]$ et le maximum est net.

3. `QCD_bis_snr_fenetre.parquet`, `QCD_bis_w_opt.parquet`, `QCD_bis_A0w_par_run.parquet`.

4. `QCD_bis_self_check.parquet`.

Δe	w_{opt}	W_{95}	SNR_{max}	$w_{\text{r\grave{e}gle}}$	w_{cert}	w_0 après le max
0.028	495	[465; 550]	0.949	indéfini	1969	aucun
0.141	445	[260; 735]	5.239	417	394	aucun
0.287	135	[105; 220]	7.254	181	193	aucun
0.498	45	[43; 47]	10.215	54	112	980

TABLE 2 – Fenêtre d’accumulation, quatre amplitudes. $w_{\text{r\grave{e}gle}}$ est la fenêtre déclarée $\text{round}(1.81 t_{1/2})$, définie seulement là où $t_{1/2}$ est lisible. w_{cert} est la fenêtre imposée par l’énoncé. w_0 est le premier w après le maximum où $\mu(w)$ devient négative. Table complète dans `QCD_bis_w_opt.parquet`.

Le changement de signe est le fait le plus net. À $\Delta e = 0.498$, $\text{SNR}(50) = +9.3695$ et $\text{SNR}(2000) = -3.3284$: sur l’horizon complet, A mesure un *déficit* d’erreur, pas un excès, parce que la forêt finit sous son socle. Le retournement intervient à $w_0 = 980$ pas à cette amplitude et jusqu’à 1770 à $\Delta e = 0.482$. Aucun w_{opt} n’est lu sur la plage où $\mu(w) \leq 0$, la maximisation y étant restreinte par construction.

La fenêtre qui entre dans D.3.bis. Pour ne pas choisir sur les mêmes données celle qui sera ensuite corrélée, la fenêtre versée à la matrice de corrélation est une *r\grave{e}gle déclarée*, $w_{\text{r\grave{e}gle}} = \text{round}(1.2564 t_{1/2} / \ln 2) = \text{round}(1.81 t_{1/2})$, qui ne lit que la courbe moyenne. W_{95} ne sert que de contrôle. Le résultat de ce contrôle se publie tel quel : $w_{\text{r\grave{e}gle}}$ tombe dans W_{95} sur 4 amplitudes sur 18. Ailleurs il est plus long, d’un facteur médian 1.1933, avec une exception à $\Delta e = 0.141$ où il vaut 0.94 fois w_{opt} .

Cet écart est une constatation, pas une conséquence du contrôle sur cas connu. Celui-ci montre que le cas fermé *sous-estime* l’optimum sur du bruit binomial, ce qui rendrait $w_{\text{r\grave{e}gle}}$ trop courte ; la mesure la trouve trop longue. Les deux faits tiennent ensemble sans que l’un explique l’autre, et la règle reste préférable à une fenêtre choisie sur les graines qui servent ensuite à la corrélation.




FIGURE 4 – $\text{SNR}(w)$ pour cinq amplitudes. La fenêtre de certificat imposée par l’énoncé, croix, tombe à droite du maximum à quatre des cinq amplitudes tracées, et à gauche à $\Delta e = 0.141$. En haut de grille la courbe passe sous zéro.

3 D.3.bis : la matrice complète, et le paradoxe de Simpson

Réponse. Partiellement oui, et la moitié de la démonstration attendue n'est pas disponible. L'aire sur fenêtre courte est mieux liée que $A(H)$ aux durées de renouvellement de la forêt : contre τ_{ARF} , la médiane stratifiée passe de +0.0526 pour $A(H)$, discernable de zéro sur aucune des 18 strates, à +0.1597 pour $A(0, w_{\text{règle}})$, discernable sur 12, et à +0.2314 pour $A(0, w_{\text{cert}})$, discernable sur 13. Contre la date d'alarme du détecteur, en revanche, c'est l'inverse : $\tau_{\text{det}}(\lambda = 8)$ est discernable sur 5 strates avec $A(H)$ et sur une seule avec $A(0, w_{\text{règle}})$. Quant à la comparaison qui paraissait la plus directe, celle des trois aires face à $S_{\text{max}}(H)$ et face à l'aire étalon, elle ne tranche rien : les six cellules portent le même lien algébrique et sont hachurées.

L'empilement, lui, fabrique de l'association partout : le rapport du coefficient empilé à la médiane stratifiée vaut 2.9696 en médiane sur les 55 paires sans lien connu, et cinq paires changent de signe entre les deux lectures.

3.1 Périmètre et exclusions

Douze métriques, 66 paires, en version empilée sur les 2000 exécutions et stratifiée par amplitude.⁵ Trois grandeurs sont écartées, avec leur motif : $\tau_{\text{swap}}(10\%)$, identique à τ_{ARF} à $M = 10$ et donc tautologique ; $\tau_{\text{det}}(\lambda = 25)$, censuré à 61.1% ; $\tau_{\text{det}}(\lambda = 50)$, censuré à 99.95%. La seule tautologie connue n'a donc pas de cellule dans la matrice, et la colonne qui la marquerait y est vide par construction.

Onze cellules portent un lien algébrique connu et sont hachurées plutôt que lues. Sept étaient identifiées d'emblée : $(S_{\text{max}}(H), A(H))$ par la forme de Lindley, $(A(H), \text{étalon})$ et $(S_{\text{max}}(H), \text{étalon})$ par l'identité approchée $e_t - \hat{p}_0 \approx \Delta e (1 - \text{acc})$, $(\int V, \text{étalon})$ par partage des votes et des sondes, et les trois emboîtements de sommes entre $A(0, w)$ et $A(H)$.

Quatre ont été ajoutées après coup, et c'est la correction la plus lourde de ce document. $S_{\text{max}}(H) = \max_{k \leq j} [A(k, j) - (j - k) \delta_P]$ est un supremum sur une famille qui contient $A(0, w) - w \delta_P$ pour tout w . Le lien de Lindley ne concerne donc pas seulement $A(H)$: il vaut pour chaque $A(0, w)$, et plus étroitement encore pour les fenêtres courtes, puisque l'argmax de Lindley tombe dans leur voisinage en haut de grille. Marquer $(S_{\text{max}}, A(H))$ seul revenait à hachurer le terme de comparaison et à inviter à lire les deux autres. Les cellules $(S_{\text{max}}, A(0, w_{\text{règle}}))$ et $(S_{\text{max}}, A(0, w_{\text{cert}}))$ sont donc hachurées elles aussi, de même que les deux cellules de $A(0, w)$ contre l'aire étalon, liées par la même identité approchée que $A(H)$.

Ce marquage retire à D.3.bis la comparaison la plus frappante. Les valeurs restent dans la table, +0.7068 pour $A(0, w_{\text{cert}})$ contre S_{max} , +0.5954 pour $A(0, w_{\text{règle}})$ et +0.3246 pour $A(H)$, les 18 strates étant discernables dans les trois cas ; mais elles ne peuvent pas soutenir un verdict, puisque le lien explique une part inconnue de l'écart.

Censure. Une cellule dont l'une des deux marges dépasse 50% de censure dans au moins une strate du domaine de décision est calculée puis hachurée : onze cellules, toutes dues aux amplitudes basses. Cette règle ne vaut que pour les cellules neuves ; le contrôle de non-régression contre la rédaction D garde la définition d'origine, les 18 strates du domaine. Les deux conventions sont publiées côte à côte : pour la paire $(\tau_{\text{ARF}}, \tau_{\text{swap}}(75\%))$, la médiane stratifiée vaut 0.097934 sur 18 strates avec la convention d'origine et 0.090037 sur 17 avec la règle, soit un rapport d'amplification de 4.72 contre 5.13.⁶

Enfin, $A(0, w_{\text{règle}})$ n'existe qu'aux 18 amplitudes où $t_{1/2}$ est lisible : ses cellules empilées portent $n = 1800$ et non 2000, et ses deux strates manquantes sont grisées.

3.2 Contrôles

Le contrôle de non-régression passe exactement : la cellule $(\tau_{\text{ARF}}, A(H))$ redonne +0.396512 empilé et +0.052559 en médiane stratifiée, rapport 7.54, valeurs de **tab:agregation** de la rédaction D. Le nombre de strates discernables de zéro y est de 0 sur 18, comme dans le rapport.

5. `QCD_bis_matrice_correlation.parquet`, une ligne par cellule avec son intervalle de confiance, son effectif et son taux de censure ; `QCD_bis_matrice_resume.parquet` pour le résumé par paire.

6. `QCD_bis_controle_conventions.parquet`, `QCD_bis_controle_censure.parquet`.

Pour $(\tau_{\text{ARF}}, S_{\text{max}}(H))$, ce document compte 14 strates discernables sur 18 contre 15 dans la rédaction D. La différence tient au nombre de rééchantillons, 1000 ici contre 2000 là, et à une graine différente ; elle porte sur une strate dont l'intervalle frôle zéro et ne change pas le verdict. C'est le chiffre de la rédaction D qui fait foi, celui-ci étant produit avec moins de rééchantillons.

Le traitement de la censure est contrôlé sur la paire la plus censurée retenue, $(\tau_{\text{ARF}}, \tau_{\text{swap}}(75\%))$. Sur le domaine de décision, l'écart entre le coefficient calculé avec imputation à l'horizon et celui calculé sur les cas complets atteint au plus 0.040259, à $\Delta e = 0.194$ où la censure vaut 0.13 ; à l'amplitude la plus censurée, $\Delta e = 0.141$ et 0.540 de censure, cet écart n'est que de 0.0087. Les deux extrêmes ne tombent donc pas sur la même strate, et le pire écart n'est pas celui de la pire censure.

Le témoin de Simpson est construit et non emprunté : sur un jeu synthétique où X et Y sont indépendants dans chaque strate mais dont les deux moyennes croissent avec l'indice de strate, le coefficient empilé vaut +0.9505, la médiane stratifiée +0.0111 avec un intervalle $[-0.0188; +0.0277]$ qui couvre zéro, et le rapport 85.5467. Sur le témoin où la relation est réelle et les moyennes constantes, empilé +0.5017 contre stratifié +0.5032, rapport 0.9970. L'indicateur ne voit Simpson que là où Simpson est. Sa médiane stratifiée de témoin, +0.0111, reste toutefois dix fois plus grande que les dénominateurs les plus petits rencontrés sur les données : le témoin valide la détection, pas le comportement du rapport quand le dénominateur s'annule.

Les intervalles de la matrice empilée sont bootstrapés *par grappes de graines* : les 100 graines étant communes aux 20 amplitudes, rééchantillonner les exécutions une à une donnerait des intervalles trop étroits.

3.3 Ce que la matrice dit, une fois les cellules liées écartées

Comparée à	Métrique d'aire	empilé	médiane stratifiée	strates discernables
τ_{ARF}	$A(0, w_{\text{cert}})$	+0.3424	+0.2314	13/18
τ_{ARF}	$A(0, w_{\text{règle}})$	+0.4583	+0.1597	12/18
τ_{ARF}	$A(H)$	+0.3965	+0.0526	0/18
$\tau_{\text{swap}}(25\%)$	$A(0, w_{\text{règle}})$	+0.5121	+0.1649	11/18
$\tau_{\text{swap}}(25\%)$	$A(H)$	+0.4567	+0.1240	9/18
$\tau_{\text{det}}(\lambda = 8)$	$A(H)$	+0.3708	+0.0548	5/18
$\tau_{\text{det}}(\lambda = 8)$	$A(0, w_{\text{règle}})$	+0.3826	+0.0032	1/18

TABLE 3 – Les seules comparaisons des trois aires qui ne portent pas de lien algébrique connu. Les cellules contre $S_{\text{max}}(H)$ et contre l'aire étalon sont hachurées et absentes de cette table.

La validation demandée par le mail est donc acquise du côté de la forêt et refusée du côté du détecteur. L'aire sur fenêtre courte est bien la meilleure des trois pour ce que l'adaptation du classifieur laisse fuiter, mesurée par les durées de renouvellement. Elle est la moins bonne pour prédire quand l'alarme partira, ce qui n'est pas contradictoire : $A(0, w)$ coupe l'intégration à la fin du transitoire, précisément là où le détecteur, lui, continue d'accumuler.

Une nuance sur le choix de la fenêtre : celle qui maximise le rapport signal sur bruit de A n'est pas celle qui maximise son pouvoir d'association. La fenêtre de certificat imposée par l'énoncé, pourtant 1.77 à 2.49 fois plus longue que w_{opt} en haut de grille, fait aussi bien ou mieux que $w_{\text{règle}}$ contre τ_{ARF} . Optimiser la lisibilité d'une grandeur et optimiser son association sont deux problèmes différents, et la section 2 répond au premier.

Le fait neuf concerne τ_{ARF} . Contre $A(H)$, sa médiane stratifiée vaut +0.0526 et aucune des 18 strates n'est discernable de zéro : c'est le verdict du rapport, inchangé. Contre $A(0, w_{\text{règle}})$, elle vaut +0.1597 et 12 strates sur 18 sont discernables. La date du premier remplacement dit donc quelque chose de l'erreur *laissée fuiter pendant le transitoire*, alors qu'elle ne dit rien de l'erreur cumulée sur l'horizon. Cela ne réhabilite pas τ_{ARF} , l'association restant faible, mais cela précise contre quoi le verdict négatif de la question D a été rendu.

3.4 L'ampleur de l'artefact d'agrégation

Sur les 55 paires sans lien connu, le rapport du coefficient empilé à la médiane stratifiée vaut 2.9696 en médiane, et 28 paires gardent au moins la moitié de leurs strates discernables de zéro. Cinq paires changent de signe entre les deux lectures.

Le maximum, 378.2781 pour $(\tau_{\text{swap}}(75\%), A(0, w_{\text{règle}}))$, n'est pas une mesure. Les 18 strates de cette paire vont de -0.1075 à $+0.0789$, aucune n'a d'intervalle excluant zéro, et la série change de signe en cours de grille : la médiane 0.001113 est le point où deux valeurs opposées se croisent, pas une estimation. Le rapport y est donc un artefact de dénominateur, et il est instable en conséquence : sous la convention réservée aux cellules neuves, qui écarte la strate trop censurée, la médiane vaut 0.002023 et le rapport 208.05. Ces valeurs se lisent comme une direction, pas comme une grandeur. La médiane des 55 paires, elle, ne bouge pas de façon sensible entre les deux conventions.

Le deuxième plus fort, 118.3557 pour $(\tau_{\text{det}}(\lambda = 8), A(0, w_{\text{règle}}))$, a le même défaut, avec une seule strate discernable sur 18. Aucun coefficient empilé n'est cité comme résultat dans ce document ni dans le rapport : la matrice empilée est montrée pour être réfutée par la stratifiée.




FIGURE 5 – Médiane des τ_b sur les 18 strates du domaine de décision. Les cellules hachurées portent un lien algébrique, ou plus de 50% de censure dans au moins une strate.




FIGURE 6 – La même matrice, toutes amplitudes empilées. À comparer cellule à cellule avec la précédente.




FIGURE 7 – Rapport des deux lectures. Une valeur de 1 signifie que l’empilement ne change rien ; les valeurs élevées marquent les paires dont le coefficient global est fabriqué par la grille d’amplitudes, y compris celles dont la médiane stratifiée n’est pas discernable de zéro, où le rapport n’a pas de contenu.




FIGURE 8 – Le paradoxe sur une paire. La pente empilée suit l’alignement des nuages par amplitude, pas la relation à l’intérieur de chacun. Chaque droite est ajustée et tracée sur l’étendue de son propre groupe.

4 D.1.bis : ce qui se passe entre les arbres

Réponse. La forêt ne se répare pas seulement en remplaçant des arbres. Le désaccord entre arbres retombe à mi-hauteur alors que la fraction d'arbres distincts renouvelés ne vaut que 0.6320 à 0.6650 sur les huit amplitudes les plus fortes : les survivants apprennent. Et le pilote instrumenté renverse l'hypothèse de départ. Après une forte rupture, les arbres neufs ne sont pas les mauvais élèves de la forêt, ils en sont les meilleurs : leur taux d'erreur vaut 0.0050 contre 0.2270 pour les survivants à $\Delta e = 0.498$. L'effet Hyde n'est pas une dégradation causée par des arbres jeunes, c'est un retard causé par des arbres âgés que le drift a rendus faux.

4.1 Le constat, avant toute mesure

Aucune table de la campagne ne porte l'erreur d'un arbre à un pas donné. `exp_QCD_campagne.py` n'enregistre que l'erreur de la forêt et les événements de remplacement ; `exp_QCD_etalon.py` interroge bien chaque arbre, mais somme immédiatement sur les 10 arbres et les 200 sondes. La variance en coupe transversale demandée par le mail n'était donc calculable depuis aucun Parquet.

Un second argument limite ce qu'une variance instantanée peut apprendre. Sur des erreurs binaires $e_m(t) \in \{0, 1\}$, la variance entre les M arbres à un instant donné vaut $\bar{p}_t(1 - \bar{p}_t)$ au facteur $M/(M - 1)$ près, où $\bar{p}_t$ est la fraction d'arbres en erreur ; le désaccord avec la majorité vaut $\min(\bar{p}_t, 1 - \bar{p}_t)$. Les deux sont la même grandeur à une transformation monotone près. Ce qu'aucune des deux ne voit, et qui fait l'effet Hyde, est l'hétérogénéité *persistante* des taux d'erreur par arbre. Elle exige des traces par arbre.

4.2 Le proxy disponible, et ses limites

$V(t)$, le désaccord instantané mesuré tous les 25 pas sur les sondes de l'étalon, est disponible sans resimuler.⁷ Il partage ses votes, ses sondes et sa fenêtre avec l'aire étalon : ce n'est pas une mesure externe, et ce point est repris en section 6. Le pas de sonde de 25 ne résout pas la montée en haut de grille, où τ_{ARF} médian vaut 28 pas.

Dans la bande où le drift agit, $V(t)$ monte de 0.0516 à $t = 0$ jusqu'à un pic de 0.2803 à $t = 50$ à $\Delta e = 0.498$, puis retombe. Le fait à retenir est la date de cette retombée rapportée au renouvellement : V revient à mi-hauteur alors que la fraction d'arbres distincts remplacés vaut 0.6410. La forêt s'est déjà réaccordée pour moitié avec un tiers de ses arbres d'origine encore en place.

4.3 Le pilote instrumenté

Le proxy ne répondant pas à la question posée, un pilote a été lancé : 5 amplitudes, 20 graines, $M = 10$, horizon 2000, soit 100 exécutions en 1.1 minute.⁸ C'est une campagne, décidée avec son coût, pas une vérification. Le contrôle exigé avant lecture est passé : sur les 100 exécutions, la trajectoire d'erreur de la forêt reproduit `QCD_traces_error_full` sans un seul pas différent, et les événements de remplacement coïncident un à un. Le sondage par arbre n'a donc consommé aucun aléa.⁹

Les taux d'erreur par arbre sont lus sur des blocs alignés sur le τ_{ARF} de chaque exécution, $[k \tau_{\text{ARF}}, (k + 1) \tau_{\text{ARF}})$, et non sur une fenêtre fixe : une fenêtre de 50 pas décalerait de 25, contre un transitoire de 28 à 38 pas en haut de grille. Les blocs 0 et 1 ne comptent aucun arbre remplacé : le bloc 0 s'arrête avant le premier remplacement par définition de τ_{ARF} , et le bloc 1 commence à cet instant, si bien que l'état lu à son début est encore vierge. La colonne des arbres neufs `y` est donc vide.

Trois lectures. D'abord, dans le bloc 0, avant tout remplacement, la variance observée est *inférieure* à celle d'un échantillonnage indépendant en haut de grille, 0.4615 à $\Delta e = 0.498$: les arbres voient les mêmes points et se trompent ensemble. Ce rapport n'est pas un test, c'est un repère.

Ensuite, l'excès dépasse 1 à tous les blocs à partir du bloc 1, et monte à 6.6924 au bloc 2 à $\Delta e = 0.498$: l'hétérogénéité entre arbres devient réelle et persistante, pas un artefact d'échantillonnage. C'est ce que la variance instantanée ne pouvait pas voir. Le remplacement n'en a pas pour autant

7. `QCD_bis_dispersion_arbres.parquet`.

8. `QCD_bis_pilote_arbres_pilote.log`, log de campagne, avec la grille, les graines, la durée et le résultat du contrôle.

9. `QCD_bis_traces_arbres_pilote.parquet`, `QCD_bis_variance_arbres.parquet`, `QCD_bis_variance_arbres_agreee.parquet`.

Δe	bloc	variance entre arbres	excès sur l'échantillonnage	taux des neufs	taux des survivants
0.028	0	0.0026	1.8821	indéfini	0.0743
0.028	2	0.0035	3.3855	0.1426	0.0694
0.416	0	0.0052	0.5027	indéfini	0.4140
0.416	2	0.0070	1.6958	0.1069	0.2139
0.498	0	0.0064	0.4615	indéfini	0.4716
0.498	2	0.0185	6.6924	0.0050	0.2270

TABLE 4 – Variance transversale des taux d'erreur par arbre, blocs alignés sur τ_{ARF} . L'excès est le rapport de la variance observée à celle qu'un échantillonnage pur donnerait si tous les arbres avaient le même taux. Les blocs 4 et 5 de $\Delta e = 0.028$ reposent sur 18 et 17 exécutions, les autres sur 20 : à cette amplitude τ_{ARF} est assez long pour que six blocs dépassent l'horizon.

l'exclusivité : en bas de grille, à $\Delta e = 0.028$, l'excès vaut déjà 1.8821 au bloc 0, avant qu'un seul arbre ait été remplacé. Les quatre blocs 0 d'excès inférieur à 1 sont tous à $\Delta e \geq 0.243$.

Enfin, le signe de l'écart entre arbres neufs et survivants s'inverse le long de la grille. À $\Delta e = 0.498$ les neufs valent 0.0050 contre 0.2270 aux survivants, un écart de -0.2220 . À $\Delta e = 0.028$ l'écart vaut $+0.0732$, les neufs étant alors les plus mauvais. La lecture est cohérente avec un acquis du journal, selon lequel la tâche devient plus facile après une forte rupture : un arbre neuf apprend directement la nouvelle règle, un survivant traîne l'ancienne. En bas de grille, où le remplacement est déclenché par le bruit, il détruit de l'information au lieu d'en apporter.




FIGURE 9 – Proxy $V(t)$, désaccord instantané, dans la bande et hors bande, avec la fraction d'arbres distincts remplacés. Témoin sans drift sur 100 exécutions.

Tree dispersion measured directly: per-tree error rates from the instrumented pilot
(5 amplitudes, 20 seeds, bit-for-bit identical to the campaign)




FIGURE 10 – Variance transversale mesurée directement sur le pilote instrumenté. À gauche par blocs alignés sur τ_{ARF} , à droite par blocs disjoints de 10 pas.

5 C.1.bis : le Z-score de la baisse d'erreur

Réponse. Négative, et l'encadrant a raison de la placer en dernier. L'instant où le Z-score franchit un seuil mesure le nombre de graines moyennées, pas la dynamique de la forêt. À $\Delta e = 0.141$ et au seuil 3, il vaut 751 pas avec 25 graines, 487 avec 50 et 353 avec 100.¹⁰ Le dénominateur décroît en $1/\sqrt{n}$: ajouter des graines fait franchir le seuil plus tôt, à dynamique strictement inchangée. Le même effet joue sur le seuil : à la même amplitude et avec 100 graines, 230, 353 et 529 pas pour les seuils 2, 3 et 4.

Trois amplitudes ne font pas une démonstration, aussi la dépendance est-elle mesurée sur toute la grille. En rapportant $t_Z(n)$ à $t_Z(100)$ pour chaque amplitude où l'instant existe aux trois tailles, la médiane vaut 1.3333, 1.3516 et 1.4091 à $n = 25$ pour les seuils 2, 3 et 4.¹¹ Le sens est le même sur 18 des 19 amplitudes au seuil 2, et sur la totalité des 18 et des 17 amplitudes aux seuils 3 et 4.

La décroissance n'est pas universelle pour autant. Sur les 54 triplets, deux ne sont pas monotones : à $\Delta e = 0.085449$ et au seuil 2, t_Z passe de 534 à 618 entre 25 et 50 graines avant de redescendre à 609 ; à $\Delta e = 0.242568$ et au même seuil, de 112 à 123 puis 92. Les deux sont au seuil le plus bas, celui où le franchissement est le plus bruité.

À $\Delta e = 0.028$, aucune des neuf combinaisons de seuil et de taille d'échantillon ne donne d'instant défini : la baisse d'erreur y vaut 0.002, sous le bruit.

La version invariante en n du même objet existe déjà : c'est le premier instant où la baisse dépasse une fraction déclarée de $e_{\text{start}} - e_{\infty}$, c'est-à-dire t_{25} , $t_{1/2}$ et t_{90} de la section 1. Ces trois-là ne dépendent pas du nombre de graines, seulement leur incertitude en dépend, ce qui est le comportement attendu d'un estimateur.




FIGURE 11 – t_Z en fonction du nombre de graines moyennées. À gauche trois amplitudes et trois seuils ; à droite toutes les amplitudes, rapportées à leur valeur à $n = 100$. Une grandeur qui décroît quand on ajoute des observations ne mesure pas le phénomène.

6 Ce qui n'a pas été fait

- **Les énoncés complets des cinq questions n'ont pas été lus.** Le fichier reçu est le corps du mail ; les réponses suivent ce texte, et peuvent manquer une exigence formulée en pièce jointe.
- **$S_{\max}(H)$ n'est pas un terme de comparaison indépendant de $A(0, w)$.** C'est un supremum sur une famille qui contient $A(0, w) - w \delta_P$ pour tout w . La comparaison des trois aires face à lui

10. QCD_bis_t_zscore.parquet.

11. QCD_bis_zscore_rapports.parquet.

- est donc en partie algébrique, dans les deux sens, et la section 3 ne s'en sert plus pour trancher. La même réserve vaut pour l'aire étalon, liée aux trois par l'identité approchée $e_t - \hat{p}_0 \approx \Delta e (1 - \text{acc})$.
- **Le verdict de forme de C.3.bis et son critère de sélection vont dans le même sens.** Le rapport $t_{90}/t_{1/2}$ décroît avec l'amplitude, et le critère de lisibilité ne se lève qu'en haut de grille : les huit amplitudes retenues sont celles où le rapport est le plus bas. Le compte de huit bascule à sept ou neuf pour deux décimales de bruit.
 - **e_∞ est déclaré non fiable à $\Delta e = 0.390998$ et $\Delta e = 0.465040$.** La seconde est l'une des huit amplitudes du test de forme, et c'est d'elle que vient la borne haute 1.9714 citée en section 1. Tous les t_q étant définis relativement à e_∞ , cette réserve se propage à eux.
 - **Le rapport d'amplification de Simpson n'est pas borné** quand la médiane stratifiée n'est pas discernable de zéro. Son maximum se lit comme une indication de direction, pas comme une mesure, et le témoin synthétique ne couvre pas cet ordre de grandeur de dénominateur.
 - **La variance par arbre n'est mesurée que sur un pilote**, 5 amplitudes et 20 graines, contre 20 et 100 pour la campagne. Les écarts entre arbres neufs et survivants ne portent donc pas d'intervalle de confiance comparable à celui des autres résultats du rapport, et les amplitudes intermédiaires ne sont pas couvertes.
 - **La multiplicité n'est pas corrigée.** La matrice stratifiée compte 66 paires sur 18 strates, soit 1188 coefficients. Aucune correction de Bonferroni ni de taux de fausses découvertes n'est appliquée : seules les cellules dont l'intervalle est loin de zéro se citent, ce qui est une règle de lecture, pas un contrôle.
 - **N_{2000} figure dans la matrice alors que le journal le déclare non tranché.** Le nombre de remplacements sur l'horizon complet y est noté anti-informatif, le drift en produisant moins que son absence, sans que la cause soit établie. Ses onze cellules sont calculées et publiées, mais aucune n'est lue comme un résultat.
 - **$w_{\text{règle}}$ dérive d'un cas fermé que les données réfutent.** La relation $w_{\text{opt}} = 1.2564\theta$ suppose un bruit d'écart-type constant ; le contrôle sur cas connu montre que la vérité vaut 2.85θ pour un bruit binomial. Le seul mérite de cette fenêtre est de ne pas être choisie sur les graines qui servent ensuite à la corrélation.
 - **Le témoin à bruit corrélé ne reproduit pas l'amplitude du régime des données**, seulement son sens. La couverture de W_{95} validée sur lui ne transporte donc pas telle quelle.
 - **Le témoin sans drift de C.3.bis tourne sur 2000 graines**, la mesure sur 100 par strate. Il ne teste pas le régime de bruit dans lequel t_q est calculé.
 - **$V(t)$ n'est pas une mesure externe.** Il partage votes, sondes et fenêtre avec l'aire étalon. Une dispersion mesurée sur un dispositif indépendant reste à faire.
 - **t_{90} n'est lisible qu'aux huit amplitudes les plus fortes**, et le verdict de forme ne vaut que là. Aux douze autres, la table le porte, grisé.
 - **Le biais de la règle de franchissement n'est pas corrigé, seulement mesuré** : environ la moitié de la fenêtre de persistance sur le cas connu. Tous les t_q publiés le portent.
 - **Les graines sont communes aux vingt amplitudes.** Les comparaisons entre amplitudes sont donc appariées, ce qui est déclaré et traité par un bootstrap par grappes de graines sur la matrice empilée, mais reste une dépendance que les strates prises isolément ignorent.