




Bonjour à tous. Notre sujet est le paradoxe du point aveugle : un modèle qui se répare lui-même peut détruire la preuve même dont son propre moniteur a besoin. Dans les vingt prochaines minutes, nous présenterons ce que nous avons formalisé, ce que nous avons mesuré, et la lecture unique qui relie les deux.

The Blind Spot Paradox

└ The problem

└ Concept drift : the rule changes, the data does not




A model trained before the change is now **wrong** on the shaded band.

Un classifieur apprend une règle à partir de données. Dans un flux, cette règle peut changer alors que les entrées gardent exactement la même distribution. C'est le concept drift : P de X ne bouge pas, P de Y sachant X bouge. C'est la situation normale d'un signal financier, où les mêmes entrées cessent de vouloir dire la même chose. Sur le banc que nous utilisons, des points du plan sont séparés par une droite. Au changement, la droite se déplace. Chaque point de la bande grisée change d'étiquette, si bien qu'un modèle entraîné avant le changement continue de prédire avec assurance, et se trompe désormais sur cette bande. La largeur de la bande est la taille du drift, notée δ .

The Blind Spot Paradox

└ The problem

└ Two defences that run at the same time




Deux défenses sont déployées ensemble. La première vit à l'intérieur du modèle. La forêt aléatoire adaptative est faite de dix arbres de décision qui votent. Chaque arbre surveille sa propre erreur avec un petit détecteur, et quand cette erreur monte, l'arbre est remplacé par un neuf. La forêt se répare localement, sans demander à personne. La seconde défense est à l'extérieur. Un détecteur cumulatif, un test de Page-Hinkley, surveille l'erreur de toute la forêt. Chaque erreur pousse une statistique vers le haut de presque un, chaque bonne réponse la tire un peu vers le bas, jamais sous zéro. Quand la statistique franchit un seuil λ , l'alarme part, et cette alarme est la seule chose qu'un opérateur humain voit.

The Blind Spot Paradox

└ The problem

└ The paradox, and what the reviewers asked



The paper's claim

The stronger the drift, the faster the repair, and the **fewer** alarms.

Two corrections requested

- 1 It races a random repair time against a constant, and assumes the trees independent.
- 2 It dates the repair at the first tree replaced, without showing that this date means anything.


Quand les deux défenses tournent ensemble, il se passe quelque chose d'inattendu. Le drift commence, les erreurs s'accumulent dans le détecteur, mais la forêt remplace des arbres, les erreurs s'arrêtent, et le tas se vide avant d'atteindre le seuil. L'article que nous étudions appelle cela le paradoxe du point aveugle : plus le drift est fort, plus la forêt se répare vite, et moins l'opérateur reçoit d'alarmes. L'article a été relu, et deux corrections ont été demandées. D'abord, il compare un temps de réparation aléatoire à un temps de détection constant, et il suppose les dix arbres indépendants sans le prouver. Ensuite, il date la réparation au moment où le premier arbre est remplacé, sans montrer que ce moment a quoi que ce soit à voir avec la disparition de l'erreur. C'est de ces deux corrections que part notre travail.

The Blind Spot Paradox

The problem

Our reading, in one map

The blind spot is not a race between two clocks, but a budget of evidence set against a threshold.




Voici tout l'exposé sur une seule carte. En haut, l'affirmation de l'article. La première colonne formalise la course : nous définissons proprement le point aveugle, nous calculons sa probabilité, et nous montrons que supposer les arbres indépendants rend l'article optimiste sur la réparation. La deuxième colonne demande ce que la date de réparation mesure réellement : c'est la date la plus précoce possible, elle se déclenche même quand rien ne change, et quand elle se déclenche l'essentiel de la preuve est déjà là. La troisième colonne relie les deux : le détecteur gagne exactement quand sa preuve atteint le seuil avant la réparation, et cette preuve explique à la fois la transition et le paradoxe. Les flèches en pointillés sont les liens entre colonnes, et la boîte du bas est la question que nous laissons ouverte. Notre lecture en une phrase : le point aveugle n'est pas une course entre deux horloges, c'est un budget de preuve face à un seuil.

The Blind Spot Paradox

I. The race

Part I — The race, formally



Commençons par la théorie : comment énoncer la course sans tricher.

The Blind Spot Paradox

I. The race

— The race is well posed, and its probability identified

The race is well posed, and its probability identified

One definition, no ad hoc rule

$\text{Miss} := \{\tau_{\text{ARP}} < \tau_{\text{Ade}}\}$

strict inequality; the alarm may never come

- a tie goes to the detector
- a silent repair, with no alarm ever, is a miss
- if neither acts, it is not

What the campaign allows

The forest always replaces a tree within the horizon, so no run is left undecided : $P_{\text{Ade}}^{\text{miss}}$ is identified.

all 20 drift sizes pooled :

λ	8	25	50
$P_{\text{Ade}}^{\text{miss}}$	0.9905	0.9715	1.0000

Without any dependence assumption

From the marginal laws alone, the blind spot at the weakest drift ($\Delta e = 0.028$, observed 1.00) is at least 0.91 at $\lambda = 8$.

τ_{ARP} : first tree replaced τ_{Ade} : first alarm Δe : drift size, the jump in error

L'article dit qu'il y a point aveugle quand la forêt se répare avant l'alarme, mais il écarte discrètement les runs où l'alarme ne vient jamais. Ce sont exactement les runs où le détecteur échoue le plus. Nous définissons donc l'événement sur la course complète, avec une seule définition et aucune règle supplémentaire. Une égalité compte pour le détecteur, parce que l'opérateur est prévenu au bon moment. Une réparation silencieuse, où l'alarme ne vient jamais, est un raté, et même le plus pur. Un run où aucun des deux mécanismes n'agit n'est pas un raté, parce qu'il n'y avait rien à effacer. Vient ensuite le problème de l'horizon fini : certains runs pourraient rester indécis. Sur notre campagne ils ne le sont pas, parce que la forêt agit toujours avant l'horizon, donc la probabilité de raté est identifiée exactement : neuf pour cent au seuil huit, quatre-vingt-dix-sept à vingt-cinq, cent à cinquante. Et avec les bornes de Fréchet, qui n'utilisent que les deux lois marginales et ne supposent rien sur le couplage des horloges, le point aveugle au drift le plus faible est déjà forcé au-dessus de quatre-vingt-dix pour cent.

The Blind Spot Paradox

└ I. The race

└ Trees share a stream : the paper is optimistic

- Given the stream, what separates two trees is their own random draws : the trees are independent conditionally.
- Hence the covariance of two trees is a variance, never negative : sharing a stream can only make them fail together — the forest is slower than the independence formula says.
- More precisely, averaging over streams, convexity gives the bound :


$$P(\tau_{\text{ABRF}} \leq s) \leq 1 - (1 - F(s))^M$$
- Conclusion : the independence formula overstates the speed of the repair, hence the blind spot ; the paper's critical ensemble size becomes a conservative ceiling, and its verdict does not change.

Le second raccourci est l'indépendance. Les dix arbres apprennent sur le même flux, ils ne peuvent donc pas être indépendants. Mais la question est : à quel niveau. Une fois le flux fixé, ce qui distingue un arbre d'un autre n'est plus que son aléa propre, les poids aléatoires du bagging en ligne. À ce niveau, sachant le flux, les arbres sont indépendants. C'est une propriété de l'algorithme, et tout le reste en découle. D'abord le sens : le seul canal entre deux arbres est le flux qu'ils partagent, et un flux partagé ne peut que les faire échouer ensemble, puisque leur covariance se réduit à une variance. La vraie forêt se répare donc plus lentement que ne le dit la formule d'indépendance. Ensuite la taille : en moyennant sur les flux, l'inégalité de Jensen donne une majoration, la probabilité que la forêt se soit déjà réparée est au plus ce que la formule d'indépendance prédit. L'article fait donc paraître la forêt plus rapide qu'elle n'est, et surestime le point aveugle. Sa taille critique d'ensemble n'est pas fausse, elle devient un plafond conservateur, et le verdict de l'article lui-même ne change pas.

The Blind Spot Paradox

II. The repair date

Part II — What the repair date measures



Passons à la seconde correction : la date que l'article utilise pour la réparation.

The Blind Spot Paradox

└ II. The repair date

└ How we measured

The campaign

- the paper's bench, rerun : 20 drift sizes $\times$ 100 seeds, 2000 steps after the change
- 2000 more runs with no change at all
- only the error and the replacement events are recorded ; every threshold is replayed offline

Reading an association

- always within one drift size : pooling, measures the drift size, not the link
- Kendall's rank correlation, with bootstrap intervals over the seeds
- steps added after seeing the data are flagged as exploratory


Un mot sur la façon dont nous avons mesuré, sans les détails d'implémentation. Nous avons rejoué le banc de l'article sur vingt tailles de drift, avec cent graines chacune, et nous observons deux mille pas après le changement. Nous avons ajouté deux mille runs où rien ne change du tout, comme témoin. La simulation n'enregistre que deux choses : l'erreur à chaque pas et les instants où des arbres sont remplacés. Tout le reste, y compris le détecteur à n'importe quel seuil, est recalculé hors ligne, si bien qu'une campagne en remplace plusieurs. Quand nous corrélons deux grandeurs, nous le faisons toujours à taille de drift fixée. La taille du drift déplace tous les indicateurs à la fois, donc une corrélation mélangeant les tailles mesure surtout la taille elle-même. Nous utilisons la corrélation de rang de Kendall avec des intervalles bootstrap, et nous signalons les étapes ajoutées après avoir regardé les données.

The Blind Spot Paradox

II. The repair date

The first replacement is the earliest possible date

The first replacement is the earliest possible date



- On every run, the first replacement comes before any other quota of renewed trees. Three quarters of the forest are renewed 6.0 to 14.3 times later.
- With no drift at all, the first replacement comes after 95 steps in median, against 118 on the weakest drift.
- On weak drifts it comes later : 346 steps at $\Delta e = 0.085$. With no drift but the same error level, it also waits 268 : the error level delays it, not the change.

L'article date la réparation au premier arbre remplacé. Par construction, c'est la plus précoce de toutes les dates possibles : le moment où trois arbres, ou la moitié, ou les trois quarts de la forêt sont remplacés vient toujours après, sur chaque run. La seule question est : combien de temps après. Sur ce drift moyen, le premier arbre tombe après quatre-vingt-six observations, et les trois quarts de la forêt après plus de douze cents. Sur la grille, les trois quarts de la forêt sont renouvelés six à quatorze fois plus tard que le premier arbre. Et il y a un fait plus inquiétant. Sur les deux mille runs sans aucun changement, la forêt remplace quand même son premier arbre, après quatre-vingt-quinze pas en médiane. Sur le drift réel le plus faible, il lui en faut cent dix-huit. Donc à faible drift, cette date ne distingue pas un vrai changement du bruit. Pire, sur un drift un peu plus fort elle vient plus tard, après trois cent quarante-six pas. Nous avons vérifié pourquoi avec un second témoin sans drift, où l'on élève seulement le niveau d'erreur en retournant des étiquettes. Au même niveau d'erreur, le premier remplacement attend aussi environ deux cent soixante-dix pas. Le détecteur interne de chaque arbre coupe moins souvent quand l'erreur est plus bruitée, donc sur les drifts faibles cette date mesure le niveau d'erreur.

The Blind Spot Paradox

└ II. The repair date

└ When the first tree goes, most of the evidence is already there

Le premier remplacement est-il au moins la fin du transitoire? Non. Quand le premier arbre est remplacé, le détecteur détient déjà entre la moitié et les trois quarts de toute la preuve qu'il accumulera jamais. Le remplacement est au milieu de l'histoire, pas à sa fin. Nous avons ensuite demandé si cette date suit quelque chose, toujours à taille de drift fixée. Avec le pic du détecteur, il y a un lien faible mais réel, visible sur quinze tailles de drift sur dix-huit. Avec l'erreur excédentaire sur tout l'horizon, il n'y a aucun lien. Mais nous avons compris pourquoi : cette aire additionne deux mille pas, donc toute erreur sur le socle est multipliée par deux mille, et la moitié de sa variance n'est que ce bruit. Si l'on ne garde que la transition, le lien revient, faible mais réel, sur treize tailles sur dix-huit. Cette dernière étape est exploratoire.

When the first tree goes, most of the evidence is already there

Evidence at the first replacement

49% to 76%
of the detector's final peak, on
the 18 drift sizes studied

Does the date track anything, within a drift size?

compared with	median link	size
detector peak	0.21	15/18
excess error, whole horizon	none	0/18
excess error, transition only	0.23	13/18


The null over the whole horizon is mostly noise : half of that area's variance comes from the estimated baseline, multiplied by the horizon.

The Blind Spot Paradox

II. The repair date

Unexpected : pooling manufactures agreement

Unexpected : pooling manufactures agreement




Pour voir tous les indicateurs d'un coup, nous en avons croisé quatorze. Le panneau de gauche mélange tous les runs : presque tout est fortement corrélé avec tout. C'est une illusion, le paradoxe de Simpson : la taille du drift déplace chaque indicateur, donc le mélange fabrique de l'accord. Le panneau de droite calcule les mêmes corrélations à l'intérieur de chaque taille de drift. L'essentiel de l'accord disparaît, et deux groupes subsistent. Un groupe mesure la preuve et les dégâts : le pic du détecteur et l'erreur excédentaire sur la transition s'accordent fortement. L'autre groupe mesure la réparation. Entre les deux groupes, les liens restent faibles. Nous avons aussi comparé les dates de remplacement à une référence analytique, la précision de la forêt sur la région dont l'étiquette a changé. La date à laquelle trois arbres sont remplacés la suit mieux que le premier arbre. Cette matrice est exploratoire.

The Blind Spot Paradox

III. Evidence vs threshold

Part III — Evidence against the threshold


La troisième partie relie les deux premières.



The Blind Spot Paradox

III. Evidence vs threshold

The race is decided before the repair




Voici l'étape clé. Un temps de réparation compte des observations. Un seuil compte des erreurs excédentaires. Ils ne sont pas dans la même unité, et l'article fait le pont avec un taux moyen d'erreurs par pas. Ce taux n'existe pas : il chute à mesure que la forêt se répare, et le détecteur oublie sa preuve chaque fois qu'il touche zéro. L'énoncé exact est bien plus simple. Regardez la statistique du détecteur jusqu'au premier remplacement, et prenez son point le plus haut : nous l'appelons $S_{\text{pré}}$. Le détecteur arrive premier si et seulement si $S_{\text{pré}}$ atteint le seuil. Avec un seuil bas, il est atteint avant la réparation ; avec un seuil haut, il ne l'est pas. C'est exact sur chaque run, ça ne demande ni taux, ni moyenne, ni hypothèse sur les arbres, et nous l'avons vérifié sur les deux mille runs.

The Blind Spot Paradox

III. Evidence vs threshold

The evidence before the repair sets the transition




Nous avons donc mesuré S pré sur chaque run. La ligne sombre est la médiane par taille de drift, la bande contient la moitié centrale des runs, et les lignes rouges sont des seuils. Au-dessus de la zone de signal faible, la médiane se situe entre treize et vingt. Un seuil sous ce niveau est atteint avant la réparation dans la plupart des runs ; un seuil au-dessus l'est rarement. C'est exactement la transition que l'article observe entre quinze et vingt-cinq, et qu'il laisse aux travaux futurs. Regardez maintenant la forme. Après les drifts moyens, S pré décroît quand le drift se renforce, parce que le premier remplacement vient plus tôt. À seuil fixé à quinze, le détecteur gagne quatre-vingt-un pour cent des courses sur les drifts moyens, et seulement dix-huit pour cent sur les plus forts. Le paradoxe, c'est cette preuve décroissante, lue face à un seuil fixe. Tout à gauche, le drift est trop faible pour accumuler quoi que ce soit : c'est un autre régime.

The Blind Spot Paradox

III. Evidence vs threshold

Stronger drifts leave no more evidence



- ♥ The paper's picture : an excess error Δe over a window τ_{ASR} , so the area stays almost constant.
- ♥ Measured over the transition, the area varies by a factor of 1.8 while the drift size varies by 5.8 : the compensation is real.
- ♥ But the paper's rectangle misestimates it by up to 43%, and over the whole horizon the area turns negative at large drifts : the new task is easier.

Pourquoi un drift violent ne laisse-t-il pas plus de preuve qu'un drift doux ? L'image de l'article est un rectangle : une erreur excédentaire de hauteur Δe , pendant une fenêtre égale au temps de réparation. Comme le temps de réparation décroît comme un sur Δe , l'aire reste presque constante. Nous avons mesuré l'aire directement. Sur la transition, elle varie d'un facteur inférieur à deux, alors que la taille du drift varie de presque six : la compensation est réelle. Mais le rectangle lui-même est faux. Il se trompe sur l'aire jusqu'à quarante-trois pour cent, parce que le premier remplacement n'est pas la largeur du transitoire. Et sur tout l'horizon, aux grands drifts, l'aire devient même négative : après le changement, la tâche est plus facile qu'avant, et l'erreur se stabilise sous son ancien niveau. La preuve existe, elle est à peu près constante, mais la dérivation qu'en fait l'article ne tient pas.

The Blind Spot Paradox

└ III. Evidence vs threshold

└ Detecting is not winning

threshold λ	alarm fires	detector arrives first	false alarms, no drift
8	95.3%	91.0%	4.15%
15	92.9%	36.3%	0.15%
20	66.2%	8.1%	0.00%
25	38.9%	2.5%	0.00%

2000 runs with drift and 2000 without, over 2000 steps

- At $\lambda = 15$ the alarm almost always fires, but mostly after the repair.
- At $\lambda = 8$ the detector wins 91% of races for 4.15% of drift-free runs with a false alarm : the paper's "no threshold escapes" does not hold on this bench.
- Not tested : the heteroscedastic streams where the paper places its false-alarm tension.

Une conséquence pratique. Détecter un drift et gagner la course sont deux choses différentes. Au seuil quinze, l'alarme part sur quatre-vingt-treize pour cent des drifts, ce qui paraît excellent, mais elle arrive avant la réparation dans seulement trente-six pour cent d'entre eux. La plupart de ces alarmes viennent après que la forêt a déjà changé. Au seuil huit, le détecteur gagne quatre-vingt-onze pour cent des courses, et environ quatre pour cent des runs où rien ne se passe lèvent une fausse alarme en deux mille pas. Au seuil douze, il gagne encore soixante-dix-neuf pour cent des courses, pour un demi pour cent de fausses alarmes. Donc sur ce banc, les seuils bas échappent bel et bien au point aveugle, et l'affirmation de l'article qu'aucun seuil n'y échappe doit être restreinte. Nous n'avons pas testé les flux financiers à volatilité groupée, où l'article situe le problème des fausses alarmes.

The Blind Spot Paradox

└ Conclusion

└ What changes in the paper

Pour résumer ce que notre travail change dans l'article. La course, qui comparait un temps aléatoire à une constante, est rendue exacte : identifiée, bornée, et décidée run par run. Le biais de l'hypothèse d'indépendance était affirmé ; il est maintenant prouvé, avec son sens. L'idée que l'erreur est revenue à la normale au premier remplacement est corrigée. Le premier remplacement comme date de réparation est qualifié : c'est la date la plus précoce et elle se déclenche sans drift. Le seuil de transition, que l'article laissait inexpliqué, est expliqué par la preuve avant la réparation. Et l'affirmation qu'aucun seuil n'échappe est restreinte aux réglages que l'article a réellement testés. Le phénomène survit à tout cela. Ce qui change, c'est son mécanisme, et sa portée.

The paper	Our result	
race the repair against a constant	race identified, bounded, decided run by run	made exact
independent trees, bias asserted	direction proven, cannot reverse	proven
error back to normal at the first replacement	it comes back later; the rectangle fails	corrected
first replacement as the repair date	earliest date, fires without drift	qualified
transition between 15 and 25, unexplained	set by the evidence before the repair	explained
no threshold escapes	$\lambda = 8$ and 12 do, on this bench	restricted

The phenomenon survives. What changes is its mechanism and its reach.

The Blind Spot Paradox

└ Conclusion

└ An open question, and what we did not do

An open question, and what we did not do

Open : a reference for adaptation

Every indicator on the detector's side reads the error, which mixes what the forest relearned with how hard the new task is. On analytic probes, the forest can relearn the changed region and lose a rare one, unseen by the error.

Not done

- one forest size, one homoscedastic bench
- decision rule fixed during the analysis
- the independence bias has a sign, not a size

Nous laissons une question ouverte. Toute mesure disponible pour le détecteur lit l'erreur, et l'erreur mélange deux choses : ce que la forêt a réappris, et la difficulté de la nouvelle tâche. Avec des sondes analytiques, des points dont nous connaissons la vraie étiquette, nous avons vu que la forêt peut réapprendre la région qui a changé tout en perdant une région rare ailleurs, et l'erreur ne voit pas cette perte. Alors quelle serait une vraie référence pour l'adaptation ? Nous n'avons pas la réponse. Et pour être honnêtes sur les limites : nous avons étudié une seule taille de forêt sur un seul banc simple, notre règle de décision a été fixée pendant l'analyse plutôt qu'avant, et nous pouvons donner le signe du biais d'indépendance mais pas sa taille.

The Blind Spot Paradox

Conclusion

Take-away

The blind spot is a budget of evidence, accumulated before the repair, set against a threshold.



Retour à la carte. Le point aveugle est réel, et il survit à toutes les corrections. Mais ce n'est pas une course entre deux horloges. C'est la preuve que la forêt laisse passer avant sa première réparation, face à un seuil fixe. Cette seule grandeur explique quand le détecteur gagne, pourquoi la transition est là où elle est, et pourquoi les drifts plus forts sont ratés plus souvent. Merci de votre attention ; nous sommes à votre disposition pour vos questions.